



Finally Report

name: Ensheng Shi (石 恩 升)
student ID number: 4119105089

2019/ 11/ 18/

1 Mathematics foundation and Key technique

优化问题的基本形式为：

$$\begin{aligned} \min \quad & f(x) \\ \text{st. } & h_i(x) = 0, i \in E = 1, 2, \dots, m_e \\ & c_i(x) \geq 0, i \in I = m_e + 1, \dots, m \end{aligned} \quad (1)$$

$$x \in R_n, h_i, c_i R_n \rightarrow R_1$$

$f(x)$ 为优化目标函数， $h(x)$ 为等式约束， $c(x)$ 为不等式约束。为了解决这个问题，我们需要知道一些关于函数，变量等的数学基础：

1. 函数的一阶导数与二阶导数

2. 范数

3. 泰勒展开

因为求解的目的是达到 $f(x)$ 的极值点，我们需要知道函数极值以及达到极值的条件。

1. 多元函数的极值

2. KKT 条件 (考虑不等式约束)

因为是多元函数，其中涉及矩阵的概念和矩阵的运算

1. 矩阵的正定性

2. 向量的正交化

3. 矩阵的分解

由于本课程多以凸优化为例，还需要介绍

1. 凸集

2. 凸函数

3. 凸优化。

最后由于算法需要进行收敛性分析，简单介绍收敛速度的判断

1.1 数学基础

1.1.1 函数的一阶导数与二阶导数

对于 n 元函数 $f(x), x = (x_1, x_2, x_3, \dots, x_n)_T \in R^n$, 梯度向量为：

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \dots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix} \quad (2)$$

有时记做 $g(x)$

二阶偏导数矩阵，也称 Hesse 阵。

$$\nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{pmatrix} \quad (3)$$

有时记作 $G(x)$

1.1.2 范数

范数用来衡量 n 维空间中两点的距离，这里指的是向量的范数。满足：

1. 非负性：对于任意的 $x \in R^n, \|x\| \geq 0$, 当且仅当 $x = 0$ 时, $\|x\| = 0$;
2. 齐次性：对于任意的 $x \in R^n, \alpha \in R, \|\alpha * x\| = |\alpha| * \|x\|$;
3. 三角不等式：对于任意的 $x, y \in R^n, \|x + y\| \leq \|x\| + \|y\|$

1.1.3 泰勒展开

一元函数的 Taylor 展开式为：

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2!}(x - x_0)^2 + \dots + o(\|x - x_0\|^n)$$

多元函数的 Taylor 展开式为：

$$f(x) = f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2} (x - x_0)^T \nabla^2 f(x_0) (x - x_0) + \dots + o(\|x - x_0\|^2)$$

在一维搜索中，我们需要构造一元函数：

$$\begin{aligned} \Phi(t) &= f(x_0 + td) = f(x_{10} + td_1, \dots, x_n^0 + td_n) \\ \Phi(t)' &= \nabla f(x_0 + td)^T d \\ \Phi(t)' &= d^T \nabla^2 f(x_0 + td) d \end{aligned} \quad (4)$$

因为在迭代过程中 $\Phi(t)' = \nabla f(x_0 + td)^T d < 0$ 所以以为搜索的函数大致形状如图1所示：




Figure 1: 一维搜索函数图

1.2 极值条件

1.2.1 多元函数的极值

多元函数中, 当 $\nabla f(x) = 0$ 时

- (1) 若 $\text{Hess} f(x_0)$ 负定, 则 $f(x)$ 在 x_0 处取得极大值;
- (2) 若 $\text{Hess} f(x_0)$ 正定, 则 $f(x)$ 在 x_0 处取得极小值;
- (3) 若 $\text{Hess} f(x_0)$ 不定, 则无法判断。

1.2.2 优化问题的一阶必要条件—KKT 条件

定理 (Kuhn - Tucker 定理) 设 x^* 是约束优化问题的局部极小解, $f(x)$ 在 x^* 处可微, 当约束规范条件

$$SFD(x^*, D) = LFD(x^*, D)$$

成立时, 存在实数 $\lambda_i^* (i = 1, 2, \dots, m)$ S.t.

$$\begin{cases} \nabla f(x^*) - \sum_{i=1}^m \lambda_i^* \nabla c_i(x^*) = 0 \\ \lambda_i^* \nabla c_i(x^*) = 0, \quad \lambda_i^* \geq 0, i \in I \end{cases} \quad (5)$$

互补松弛条件 $\lambda_i^* \nabla c_i(x^*) = 0$ 是为了让拉格朗日乘子法成立, 对于 λ 的非负性要求是在 Farkas 引理里引入的。

证明的思路为: Farkas lemma:

$$1. \begin{cases} Ax \leq 0 \\ c^T x \geq 0 \end{cases} \quad 2. \begin{cases} A^T y \leq c \\ y > 0 \end{cases}$$

公式一和公式二 iff 一个有解。约束规范条件 $SFD(x^*, D) = LFD(x^*, D)$ 可得

$$\nabla f(x^*)^T d \geq 0 \quad \forall d \in LFD(x^*, D)$$

根据 LFD(x*,D) 定义可以得到方程组:

$$\begin{cases} \nabla c_i(x^*)^T d = 0 & i \in E \\ \nabla c_i(x^*)^T d = 0 & i \in I^* \\ \nabla f(x^*)^T d < 0 \end{cases} \quad \text{无解, 也就是} \begin{cases} Ad \leq 0 \\ \nabla f(x^*)^T d > 0 \end{cases} \quad A = [\nabla c_i(x^*)^T, -\nabla c_i(x^*)^T, \quad i \in E \quad \nabla -f(x^*)^T] \quad (6)$$

根据 farkas lemma,

$$\begin{cases} A^T y \leq f(x^*) \\ y > 0 \end{cases} \quad (7)$$

有解, 其中 $y = (\mu_{*-T}, \mu_{*+T}, \omega_{*-T})^T$ 也就是部分 λ , 加上互补松弛条件刚好使得拉格朗日乘子法的梯度等于零。构成了一阶必要条件。

定理 2(二阶充分条件)

(1) 当 x 为 KKT 点,

(2) 对于 $\forall d \in M = \{d \in R_n \mid d^T \nabla c_i(x^*) = 0, i \in E \cup I^*\}$ 都有

$$d^T \nabla_x^2 L(x^*, \lambda^*) d > 0$$

则 x^* 为严格局部最优解。

1.3 线性代数基础

1.3.1 矩阵的正定性

矩阵的正定的定义: $x^T A x > 0, A$ 为正定矩阵;

$x^T A x \geq 0, A$ 为半正定矩阵;

$x^T A x < 0, A$ 为负定矩阵;

1.3.2 向量的正交化

设 $\alpha_1, \alpha_2, \dots, \alpha_n$ 是 n 维欧式空间 V 的一个基, 若令:

$$\begin{aligned} \beta_1 &= \alpha_1, \\ \beta_2 &= \alpha_2 - \frac{\langle \alpha_2, \beta_1 \rangle}{\langle \beta_1, \beta_1 \rangle} \beta_1 - \dots - \beta_n - \frac{\langle \alpha_n, \beta_1 \rangle}{\langle \beta_1, \beta_1 \rangle} \beta_1 - \frac{\langle \alpha_n, \beta_2 \rangle}{\langle \beta_2, \beta_2 \rangle} \beta_2 - \dots - \frac{\langle \alpha_n, \beta_{n-1} \rangle}{\langle \beta_{n-1}, \beta_{n-1} \rangle} \beta_{n-1} \end{aligned} \quad (8)$$

则 $\beta_1, \beta_2, \dots, \beta_n$ 就是 V 的一个正交基, 若在令

$$e_i = \frac{\beta_i}{\|\beta_i\|}$$

就得到了 V 的标准正交基 e_1, e_2, \dots, e_n .

1.3.3 矩阵的分解

1. LU 分解

如果顺序主子式不等于 0，再算 u_{ii} 时，其分子是主子式，算 l_{ji} 时分母为 u_{ii} 。

对于矩阵

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1i} \\ a_{21} & a_{22} & \cdots & a_{2i} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} = LU \quad (9)$$

其中 LU 分别为：

$$L = \begin{pmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & \vdots & \ddots & \\ l_{n1} & l_{n2} & \cdots & 1 \end{pmatrix} U = \begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ & u_{22} & \cdots & u_{2n} \\ & \ddots & & \vdots \\ & & & u_{nn} \end{pmatrix} \quad (10)$$

s.t $A = LU$ Then $Ax = b \Rightarrow Ly = b, Ux = y$.

2. 半正定矩阵的 LDL^T 分解

对于矩阵 A

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1i} \\ a_{21} & a_{22} & \cdots & a_{2i} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} = LU = \begin{pmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & \vdots & \ddots & \\ l_{n1} & l_{n2} & \cdots & 1 \end{pmatrix} \begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ & u_{22} & \cdots & u_{2n} \\ & \ddots & & \vdots \\ & & & u_{nn} \end{pmatrix} \quad (11)$$

$$= \begin{pmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & \vdots & \ddots & \\ l_{n1} & l_{n2} & \cdots & 1 \end{pmatrix} \begin{pmatrix} m_{11} & & & \\ & m_{22} & & \\ & & \ddots & \\ & & & m_{nn} \end{pmatrix} \begin{pmatrix} 1 & u_{12} & \cdots & u_{1n} \\ & 1 & \cdots & u_{2n} \\ & & \ddots & \vdots \\ & & & 1 \end{pmatrix}$$

if $A^T = A$ then, $M = L$, that is $A = LDL^T$

如果 A 时半正定的

$$A = LDL^T = LD^{\frac{1}{2}}D^{\frac{1}{2}}L^T = GG^T$$

3. QR 分解 QR 分解是把矩阵分解成一个正交矩阵与一个上三角矩阵的积。QR 分解经常用来解线性最小二乘法问题。课上的,QR 分解Householder




Figure 2: QR 分解示意图

变换，其次还有 Gram-Schmidt 正交化等方法。其中，Q 是一个标准正交方阵，R 是上三角矩阵。

假设 A 是一个 5×4 的矩阵，用 \times 号表示本次变换未变化的元素，用 $+$ 号表示本次发生变换的元素，H 矩阵等效于对右侧的 A 矩阵进行行操作 四次

$$\begin{aligned}
 H_1 A &= H_1 \begin{pmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \end{pmatrix} = \begin{pmatrix} + & + & + & + \\ 0 & + & + & + \\ 0 & + & + & + \\ 0 & + & + & + \\ 0 & + & + & + \end{pmatrix} \\
 H_2 &\begin{pmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \end{pmatrix} = \begin{pmatrix} \times & \times & \times & \times \\ 0 & + & + & + \\ 0 & 0 & + & + \\ 0 & 0 & + & + \\ 0 & 0 & + & + \end{pmatrix} \\
 H_3 &\begin{pmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & 0 & \times & \times \\ 0 & 0 & \times & \times \\ 0 & 0 & \times & \times \end{pmatrix} = \begin{pmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & 0 & + & + \\ 0 & 0 & 0 & + \\ 0 & 0 & 0 & + \end{pmatrix}
 \end{aligned}$$

Figure 3: QR 分解过程示意图

变换之后，A 就转化成一个上三角矩阵。并且如果 A 是列向量不相关，则 R 矩阵是非奇异矩阵。 $Q^T A = (R, 0)^T$, $Q^T = H_4 H_3 H_2 H_1$

1.4 凸优化

1.4.1 凸集

集合 $X, x \in R^n$ is convex iff

$$\alpha x_1 + (1 - \alpha)x_2 \in X, \quad \forall x_1, x_2 \in X, \quad \forall \alpha \in [0, 1]$$




Figure 4: convex set

1.4.2 凸函数

X a convex set in \mathbb{R}^n . $f(x): X \rightarrow \mathbb{R}$ is convex iff

$$f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2) \quad , \quad \forall x_1, x_2 \in X, \forall \alpha \in [0, 1]$$




Figure 5: Convex function

1.4.3 凸优化

For a convex function $f(x)$ over a convex set X is convex programming.

1.5 收敛速度

假设 x^k 收敛与

2 Method

一维搜索中：精确搜索和非精确搜索
无约束优化问题：最速下降法，牛顿法和拟牛顿法
线性约束优化问题：有效集法
非线性优化问题：罚函数法

代优化算法：遗传算法等

3 Acquirement and Suggestion

3.1 Experience

3.2 Suggestion

1. 建议小组进行作业，可以进行讨论 2. 班级人数较少的情况下可以进行小组展示，做 final report 的 presentation.